

Teste t na regressão

Variâncias e covariâncias

Lembrando que:

S_{xx} é a variação total elevada ao quadrado de x em relação à média \bar{x}

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

S_{yy} é a variação total elevada ao quadrado de y em relação à média \bar{y}

$$S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$$

Temos também que as variância σ_X^2 e σ_Y^2 são:

$$\sigma_X^2 = \frac{S_{xx}}{n}$$

$$\sigma_Y^2 = \frac{S_{yy}}{n}$$

S_{xy} é o produto da variação total de cada variável em relação à sua média \bar{x} e \bar{y} :

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

A covariância $Cov(X, Y)$ é:

$$Cov(X, Y) = \frac{S_{xy}}{n}$$

Regressão simples

Conforme foi demonstrado na entrega 2 do projeto, os resultados para regressão de mínimos quadrados são:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{S_{xy}}{S_{xx}}$$

Lembrando que $\hat{\beta}_0$ e $\hat{\beta}_1$ são os estimadores encontrados a partir dos dados para os parâmetros β_0 e β_1 do modelo de regressão.

Erros na regressão

Soma dos quadrados dos resíduos

A soma dos quadrados dos resíduos é o quadrado da variação encontrada nos dados que **não é explicada** pelo modelo de regressão. Ou seja, é a diferença entre y_i que está presente nos dados e o valor \hat{y}_i que a reta dá para o x_i correspondente.

Este valor costuma ser chamado de soma dos quadrados dos resíduos (*SQRes*) ou também *error sum of squares* ou SS_E

$$SQRes = SS_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \epsilon_i^2$$

Soma dos quadrados da regressão

É a variabilidade que é explicada pela regressão. Tipicamente é chamada de *SQR* ou SS_R

$$SQReg = SS_R = (\hat{y}_i - \bar{y})^2$$

Soma dos quadrados totais

É a soma da variabilidade total presente no modelo. Costuma ser chamado de *SQT* ou de SS_T .

$$SQT = SS_T = \sum_{i=1}^n (y_i - \bar{y})^2$$

A soma dos quadrados totais é a soma da porção explicada pela regressão com a parte que não é explicada.

$$SS_T = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y}_i)^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2 = SS_R + SS_E = SQReg + SQRes$$

Variância dos erros do modelo de regressão

Para o método dos mínimos quadrados funcionar, foi assumido que os resíduos ou erros têm média zero e distribuição normal.

Uma estimativa para a variância σ^2 dos resíduos é:

$$\hat{\sigma}^2 = \frac{SS_E}{n-2}$$

Testes dos coeficientes β_0 e β_1 na regressão

Vamos testar que a inclinação β_1 do modelo de regressão é igual a algum valor constante c

As hipóteses ficarão:

$$H_0 : \beta_1 = c$$

$$H_1 : \beta_1 \neq c$$

A estatística de teste ficará então:

$$T_0 = \frac{\hat{\beta}_1 - c}{\sqrt{\hat{\sigma}^2 / S_{xx}}}$$

Esta estatística segue uma distribuição t com $n-2$ graus de liberdade sob a hipótese nula $H_0 : \beta_1 = c$. Esta hipótese nula será rejeitada se o valor da estatística de teste for:

$$|t_0| = t_{\alpha/2, n-2}$$

Para o teste do coeficiente β_0 pode-se proceder da forma a seguir, em que d é uma constante qualquer.

Hipóteses:

$$H_0 : \beta_0 = d$$

$$H_1 : \beta_0 \neq d$$

A estatística de teste fica:

$$T_0 = \frac{\hat{\beta}_0 - d}{\sqrt{\hat{\sigma}^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

Portanto a hipótese nula deve ser rejeitada se:

$$|t_0| = t_{\alpha/2, n-2}$$

Coeficiente de determinação R^2

É uma medida de quão bem uma regressão descreve os dados.

$$R^2 = 1 - \frac{SS_E}{SS_T}$$